## Рубежный контроль №2

## Широков Павел ИУ5-21М

Тема: Методы обработки текстов

Решение задачи классификации текстов.

Классификатор 1: LogisticRegression

Классификатор 2: Multinomial Naive Bayes (CNB)

- Для каждого метода необходимо оценить качество классификации
- Сделать вывод о том, какой вариант векторизации признаков в паре с каким классификатором показал лучшее качество.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_report
from sklearn.metrics import confusion_matrix
from sklearn.model selection import cross val score
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean absolute error, mean squared error, mean squared log error
from sklearn.metrics import roc curve, roc auc score
from sklearn.naive bayes import MultinomialNB
from sklearn.linear_model import LogisticRegression
import seaborn as sns
from collections import Counter
from sklearn.datasets import fetch_20newsgroups
import matplotlib.pyplot as plt
from sklearn.svm import SVC, NuSVC, OneClassSVM, SVR, NuSVR, LinearSVR
%matplotlib inline
sns.set(style="ticks")
# !pip install category_encoders
```

```
categories = ["talk.politics.guns", "alt.atheism", "sci.med", "rec.autos"]
newsgroups = fetch_20newsgroups(subset='train', categories=categories)
data = newsgroups['data']
```

## Анализируем датасет и готовим категориальный признак

```
def accuracy score for classes(
    y true: np.ndarray,
    y_pred: np.ndarray) -> Dict[int, float]:
    Вычисление метрики accuracy для каждого класса
    y true - истинные значения классов
    y_pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y_true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp_data_flt = df[df['t']==c]
        # расчет ассuracy для заданной метки класса
        temp_acc = accuracy_score(
            temp_data_flt['t'].values,
            temp_data_flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp_acc
    return res
def print accuracy score for classes(
    y_true: np.ndarray,
    y_pred: np.ndarray):
    Вывод метрики accuracy для каждого класса
    accs = accuracy_score_for_classes(y_true, y_pred)
    if len(accs)>0:
        print('Метка \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))
```

```
vocabVect = CountVectorizer()
```

```
vocabVect.fit(data)
corpusVocab = vocabVect.vocabulary_
print('Количество сформированных признаков - {}'.format(len(corpusVocab)))
     Количество сформированных признаков - 37176
for i in list(corpusVocab)[1:10]:
    print('{}={}'.format(i, corpusVocab[i]))
     thom=33375
     morgan=23251
     ucs=34360
     mun=23527
     ca=8754
     thomas=33376
     clancy=9784
     subject=32210
     re=28101
test_features = vocabVect.transform(data)
test_features
     <2214x37176 sparse matrix of type '<class 'numpy.int64'>'
             with 375168 stored elements in Compressed Sparse Row format>
def VectorizeAndClassify(vectorizers list, classifiers list):
    for v in vectorizers list:
        for c in classifiers_list:
            pipeline1 = Pipeline([("vectorizer", v), ("classifier", c)])
            score = cross_val_score(pipeline1, newsgroups['data'], newsgroups['target'], s
            print('Векторизация - {}'.format(v))
            print('Модель для классификации - {}'.format(c))
            print('Accuracy = {}'.format(score))
            print('======')
vectorizers list = [CountVectorizer(vocabulary = corpusVocab), TfidfVectorizer(vocabulary
classifiers list = [LogisticRegression(), MultinomialNB()]
VectorizeAndClassify(vectorizers_list, classifiers_list)
       extra warning msg= LOGISTIC SOLVER CONVERGENCE MSG,
     /usr/local/lib/python3.7/dist-packages/sklearn/linear_model/_logistic.py:818: Con
     STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
     Increase the number of iterations (max_iter) or scale the data as shown in:
         https://scikit-learn.org/stable/modules/preprocessing.html
     Please also refer to the documentation for alternative solver options:
         https://scikit-learn.org/stable/modules/linear model.html#logistic-regression
       extra_warning_msg=_LOGISTIC_SOLVER_CONVERGENCE_MSG,
     Векторизация - CountVectorizer(vocabulary={'00': 0, '000': 1, '0000': 2, '0000001
                                 '00014': 4, '000152': 5, '000406': 6,
                                 '0005111312': 7, '0005111312na3em': 8, '000601': 9,
                                 '000710': 10, '000mi': 11, '000miles': 12,
                                 '000s': 13, '001': 14, '0010': 15, '001004': 16,
                                 '001125': 17, '001319': 18, '001642': 19, '002': 20,
```

```
'002142': 21, '002651': 22, '003': 23,
                           '003258u19250': 24, '0033': 25, '003522': 26,
                           '004': 27, '004021809': 28, '004158': 29, ...})
Модель для классификации - LogisticRegression()
Accuracy = 0.951219512195122
_____
Векторизация - CountVectorizer(vocabulary={'00': 0, '000': 1, '0000': 2, '0000001
                           '00014': 4, '000152': 5, '000406': 6,
                           '0005111312': 7, '0005111312na3em': 8, '000601': 9,
                           '000710': 10, '000mi': 11, '000miles': 12,
                           '000s': 13, '001': 14, '0010': 15, '001004': 16,
                           '001125': 17, '001319': 18, '001642': 19, '002': 20,
                           '002142': 21, '002651': 22, '003': 23,
                           '003258u19250': 24, '0033': 25, '003522': 26,
                           '004': 27, '004021809': 28, '004158': 29, ...})
Модель для классификации - MultinomialNB()
Accuracy = 0.9864498644986449
______
Векторизация - TfidfVectorizer(vocabulary={'00': 0, '000': 1, '0000': 2, '0000001
                           '00014': 4, '000152': 5, '000406': 6,
                           '0005111312': 7, '0005111312na3em': 8, '000601': 9,
                           '000710': 10, '000mi': 11, '000miles': 12,
                           '000s': 13, '001': 14, '0010': 15, '001004': 16,
                           '001125': 17, '001319': 18, '001642': 19, '002': 20,
                           '002142': 21, '002651': 22, '003': 23,
                           '003258u19250': 24, '0033': 25, '003522': 26,
                           '004': 27, '004021809': 28, '004158': 29, ...})
Модель для классификации - LogisticRegression()
Accuracv = 0.971093044263776
Векторизация - TfidfVectorizer(vocabulary={'00': 0, '000': 1, '0000': 2, '0000001
                           '00014': 4, '000152': 5, '000406': 6,
                           '0005111312': 7, '0005111312na3em': 8, '000601': 9,
                           '000710': 10, '000mi': 11, '000miles': 12,
                           '000s': 13, '001': 14, '0010': 15, '001004': 16,
                           '001125': 17, '001319': 18, '001642': 19, '002': 20,
                           '002142': 21, '002651': 22, '003': 23,
                           '003258u19250': 24, '0033': 25, '003522': 26,
                           '004': 27, '004021809': 28, '004158': 29, ...})
Модель для классификации - MultinomialNB()
Accuracy = 0.9774164408310749
```

## Лучшая точность была у CountVectorizer с MultinomialNB - 0.986

√ 35 сек. выполнено в 21:07

×